

T2 – Modelo de Linguagem Word2Vec

Objetivo: Construir um modelo de linguagem Word2Vec usando como base a literatura sobre esse modelo. São objetivos também avaliar de forma intrínseca e extrínseca esse modelo, bem como comparar os word embeddings do modelo construído com outras abordagens.

Etapas:

1. **Revisão da arquitetura e do algoritmo de treinamento da MultiLayer Perceptron.**
2. **Leitura das publicações sobre o modelo de linguagem Word2Vec** (ver material no moodle). Para apoiá-lo, você pode procurar códigos abertos usados para o treinamento de Word2Vec (você pode usar alguma implementação tal como a do PyTorch).
3. **Busca de datasets de domínio semelhante ao dos dados de teste**, elaborados no T1. Os dados usados no T1 não podem fazer parte dos dados de treinamento do modelo a ser gerado.
4. **Pré-processamento dos textos do corpus**, conforme a literatura da área. Foi decidido em aula o uso de n-gramas em nível de palavras. Faça testes para diferentes tamanhos de janela sendo a menos de no mínimo $n=3$. Use o pré-processamento que julgar necessário como normalização para caixa baixa, tokenização (em palavras) e remoção se julgar necessário de pontuação e caracteres especiais. Recomenda-se usar o mesmo pré-processamento feito no artigo do Word2Vec.
5. **Construção do modelo de Linguagem:** Topologia da MLP $k \times n \times k$, onde k é o comprimento do dicionário e n a quantidade de neurônios da camada oculta. O valor k será tanto a quantidade de entradas quanto a quantidade de neurônios da camada de saída. E o valor n será a dimensão dos embeddings. O desenvolvimento de um modelo de linguagem requer recursos computacionais. De acordo com os seus recursos, defina um valor para k de no mínimo 2000 palavras cuja frequência seja muito significativa. Os valores de n podem variar, iniciando em 100. Teste ao menos mais 2 valores para n . Os valores de k e n devem ser discutidos ao longo do desenvolvimento do modelo.

Nesse item também devem ser considerados a configuração do algoritmo, treinamento do modelo e extração dos word embeddings.

6. **Métodos de avaliação intrínseca e extrínseca.** A intrínseca corresponde a forma de avaliação que irá analisar a qualidade dos word embeddings avaliando a própria estrutura. Já a extrínseca irá analisar os embeddings a partir do resultado em uma tarefa.
 - a. Avaliação Intrínseca: realizada a partir de dois corpora. Será usado um corpus anotado pela turma no T1 e outro a ser disponibilizado no moodle em breve.
 - b. Avaliação extrínseca: avaliação na tarefa de categorização de texto. Será usado o dataset gerado pelo grupo no T1 e também outro a ser disponibilizado no moodle em breve.
 - c. Escolha um outro modelo de linguagem e repita as avaliações 'a' e 'b'.
 - d. Analisar e comparar os resultados.

7. Elaboração de apresentação.

Pontuação:

Busca de datasets, pré-processamento do corpus e construção do modelo de linguagem	3,0
Avaliação intrínseca usando dataset de similaridade construído pela turma para T1	1,0
Avaliação intrínseca usando dataset de similaridade público	1,0
Avaliação extrínseca usando categorização de texto usando o dataset elaborado no T1	1,0
Avaliação extrínseca usando categorização de texto usando o dataset público	1,0
Execução das avaliações com outro modelo de linguagem e comparação dos resultados	2,0
Análise de Resultados e relatório no formato de apresentação	1,0

Roteiro de apresentação

1. Descrição do dataset e pré-processamento para geração do modelo de linguagem (incluir detalhes como tamanho do vocabulário e embeddings, configurações, etc)
2. Descrição dos datasets de avaliação intrínseca e apresentação dos resultados. Análise dos resultados.

3. Descrição dos datasets de avaliação extrínseca e apresentação dos resultados. Análise e comparação dos resultados. (indicar o outro modelo de linguagem que foi usado)

4. Conclusão

Observações:

- O trabalho será acompanhado ao longo das aulas.
- O uso de ferramentas de IA deve ser mencionado explicitamente no trabalho.
- No dia da apresentação todos os integrantes do grupo devem estar presentes.